

Prueba técnica – Ingeniero(a) de Inteligencia Artificial Junior

Sofía Jaramillo Chavarría

1 Metodología

1.1 Calidad de los datos

El análisis de calidad del dataset se realizó siguiendo las dimensiones de completitud, consistencia, duplicidad e integridad referencial, siguiendo la metodología CRISP-DM. El dataset original contenía 515 registros con valores nulos en edad (4), sexo (4), peso (6) y altura (6), representando menos del 4% del total. Se detectaron edades negativas y superiores a 120 años, IDs no únicos y formatos de fecha inconsistentes. La integridad de los datos se verificó comparando los IDs de pacientes con los archivos de señal ECG disponibles, confirmando que todos los pacientes contaban con su señal correspondiente.

Los registros con valores nulos fueron eliminados dado su bajo porcentaje, con el fin de evitar introducir sesgos. Las edades fuera de rango y los duplicados también fueron eliminados, mientras que las fechas se estandarizaron al formato YYYY-MM-DD. Para la detección de datos atípicos se emplearon boxplots y la distancia de Mahalanobis. Los valores atípicos en frecuencia cardíaca fueron preservados por su potencial relevancia clínica, se sugiere validar con equipo médico. Como resultado, se obtuvo un dataset limpio de 475 registros.

1.2 Análisis exploratorio de los datos

El EDA reveló una población compuesta por 52% hombres y 48% mujeres, con edad promedio de 54.4 años. La variable objetivo presentó un desbalance moderado: 60.2% Normales y 39.8% Anormales. Se evaluaron las distribuciones de las variables: edad, peso, altura y frecuencia cardíaca (ya que las otras variables del dataset como la fecha, la frecuencia y la derivación no aportaban información debido a su papel o a que eran constantes). Con gráficos de cajas y estadísticos descriptivos usando el test de Welch, se llegó a que la relación más fuerte entre alguna variable y la etiqueta (normal y anormal) era la frecuencia cardíaca (Figura 2a).

Se realizaron algunos cálculos con la información de cada ECG, se calculó el periodo de muestreo como la diferencia entre la toma de muestras, la frecuencia es $\frac{1}{\text{periodo}}$, se calculó la desviación estándar (std_mV) de ecg_mV y se calculó el rango de amplitud ($range_mV$) como $\max(ecg_mV) - \min(ecg_mV)$. Se identificó que $range_mV$ separa las clases de forma casi perfecta (Figura 1), sin solapamiento, lo cual es inusual y sugiere una posible inyección artificial de picos de amplitud en el proceso de generación del dataset. Por esta razón se excluyó del modelado, prefiriendo std_mV , que mostró una diferencia significativa entre clases pero con solapamiento razonable.

Los espectros de la (Figura 3) muestran mayor amplitud y variabilidad en los pacientes Anormal frente a los Normal, consistente con la desviación y el rango calculado.





Figure 1: Distribución de std_mV y range_mV por etiqueta.



(a) Comparaciones por grupo, gráfico de caja para la frecuencia cardíaca y la etiqueta.

(b) Correlación entre variables, las más fuertes con la etiqueta son el rango, la desviación y la frecuencia.




Figure 3: Ejemplos de señal ECG cruda (10 segundos) para pacientes con etiqueta Normal y Anormal, seleccionados aleatoriamente.

1.3 Ingeniería de características

A partir del dataset limpio, se calcularon dos variables adicionales: el IMC ($\text{peso}/\text{altura}^2$) y la desviación estándar de la señal ECG (std_mV). Estas features se seleccionaron por su relevancia clínica y su potencial capacidad predictiva identificada en el EDA. El dataset resultante contiene 475 registros con 16 columnas, incluyendo las variables clínicas originales y las nuevas características derivadas.

1.4 Modelado

Se implementó un modelo baseline de regresión logística con `class_weight='balanced'` para compensar el desbalance de clases. Las variables utilizadas fueron: edad, sexo, IMC, frecuencia cardíaca y std_mV . Los datos se dividieron en entrenamiento (70%), validación (15%) y prueba (15%), con estandarización de variables numéricas. La regresión logística fue seleccionada por su interpretabilidad, fundamental en un contexto clínico donde las decisiones deben ser auditables y explicables.

El modelo alcanzó un AUC-ROC de 0.852 y un F1-score de 0.754 en el conjunto de prueba. La frecuencia cardíaca fue el predictor más relevante (coeficiente 1.216), seguida por std_mV (0.883) y edad (0.287). Mientras IMC (-0.172) y sexo (-0.099). El análisis de error por cuartiles no evidenció sesgos significativos por edad, IMC o sexo (Figura 4), consistente con la correlación entre variables (Figura 2b).

En el conjunto de prueba del dataset limpio, el modelo clasificó correctamente 34 de 43 pacientes Normales y 23 de 29 Anormales, con 9 falsos positivos y 6 falsos negativos. Estos resultados, junto con un AUC-ROC de 0.852, indican que el modelo distingue razonablemente bien entre ambas clases sin depender únicamente de la clase mayoritaria, aunque el número de falsos negativos (una categoría sensible pues implica pacientes con ECG anormal no detectados) sugiere que el modelo aún requiere validación adicional antes de considerarse apto para apoyo diagnóstico real. Como baseline el modelo cumple su propósito en establecer un punto de comparación y ser una base para modelos más sólidos.




Figure 4: Error absoluto promedio por cuartiles de frecuencia cardíaca, edad e IMC en el conjunto de prueba.

Dado el desbalance moderado de clases, se priorizó el F1-score sobre accuracy debido a que combina precisión y recall. El modelo obtuvo un F1-score de 0.754 en el conjunto de prueba, reflejando un balance razonable entre detectar casos Anormales y evitar falsas alarmas.

2 Problemas encontrados

- Formatos de fecha inconsistentes: Se encontraron tres formatos diferentes, lo que requirió estandarización manual.
- Valores imposibles: Edades negativas y superiores a 120 años fueron eliminadas por considerarse errores de entrada.
- Desbalance de clases: La proporción 60/40 entre clases Normales y Anormales teniendo que considerar métricas robustas como F1-score y AUC-ROC en lugar de accuracy.

3 Supuestos y limitaciones

- Linealidad: La regresión logística asume una relación lineal, por lo que relaciones no lineales o interacciones entre variables no fueron capturadas en este baseline.
- Independencia de errores: Se asume que los registros son independientes, aunque podrían existir correlaciones no consideradas.
- Tamaño muestral: Con 475 registros, el modelo es adecuado para un baseline, pero limitado para explorar interacciones complejas.

4 Decisiones tomadas

Decisión	Justificación
Eliminar nulos en edad, sexo, peso y altura	Bajo porcentaje (<4%); evita introducir sesgos de imputación
Eliminar edades negativas y >120 años	Valores clínicamente imposibles; errores de entrada
Estandarizar fechas a YYYY-MM-DD	Necesario para análisis temporal y consistencia
Usar regresión logística	Interpretabilidad y trazabilidad, prioritarias en contexto clínico
Incluir std_mV como feature	Captura variabilidad de la señal, con solapamiento razonable entre clases
Excluir range_mV del modelo	Separación casi perfecta entre clases; sospecha de artificialidad
Excluir peso y altura del modelo	No mostraron poder predictivo en el EDA
Usar class_weight='balanced'	Compensa el desbalance 60/40 sin sobremuestrear

5 Trabajo futuro

Si tuvieras dos días adicionales para mejorar este modelo, ¿qué hipótesis probarías primero y por qué?

Probaría dividir la señal ECG en sus intervalos característicos (ondas P, complejo QRS, onda T) en lugar de analizarla solo como un ciclo completo. La hipótesis es que analizar cada intervalo por separado (con su propia duración y amplitud) puede revelar patrones que se pierden al resumir toda la señal en una sola métrica como std_mV, ya que dos pacientes con variabilidad similar en todo el ciclo podrían ser diferentes notablemente en un intervalo específico.

Para esto, buscaría una herramienta de procesamiento de señales ECG que, a partir de la señal cruda de cada paciente, identifique automáticamente esta separación por intervalos. A partir de ahí, se podrían calcular duración y amplitud por intervalo y agregarlas como nuevas features del modelo. También validaría con mayor profundidad la sospecha de artificialidad en `range_mV`, idealmente contrastando contra el dataset PTB-XL original, para descartar que el proceso de generación de errores del dataset haya introducido una relación entre esta variable y la etiqueta.

6 Entregables

6.1 Repositorio

<https://github.com/sofiajch07/salva-health-technical-test>

Con historial de commits que refleja el proceso de desarrollo y la trazabilidad del proyecto. Incluye notebooks organizados por etapa (01_data_quality, 02_eda, 03_feature_engineering, 04_modeling), scripts reutilizables en `src/`, README con instrucciones de instalación y ejecución, y archivo `requirements.txt` con las dependencias del proyecto.

6.2 Versionamiento dataset

Se versionaron tres estados del dataset:


- v1.0 (raw): Datos originales (515 registros) en `data/v1_raw/`
- v2.0 (clean): Post-corrección de calidad (475 registros) en `data/v2_clean/`
- v3.0 (features): Con variables derivadas (IMC, `std_mV`) en `data/v3_features/`

La evidencia se puede encontrar en la carpeta `data` del repositorio. Cada versión incluye metadatos y documentación de cambios en archivos JSON. Este versionamiento se hizo por medio de código, se puede ver el código en el archivo `src/data_versioning.py`.

6.3 Consumo desde la nube

El dataset fue subido a Azure Storage y consumido desde allí en los notebooks de EDA y modelado mediante lectura remota, esto se hizo por medio de una variable de entorno y el código para la lectura y cargue de archivos a la nube se encuentra en el código en la ubicación `src/cloud_storage.py`.

Commits




The screenshot shows the commit history of the repository. It lists several commits by user sofiajch07, including features for modeling utilities, version 3.0 of the patient dataset, EDA utilities, and Azure cloud storage utilities. The commits are grouped by date, with the most recent ones from July 6, 2026, and an older one from July 4, 2026.

(a) Evidencia commits para trazabilidad

salva-health-data

Contenedor



The screenshot shows the Azure portal interface for the 'salva-health-data' container. It displays the 'Información general' (General Information) tab, which includes details about the container's authentication method (Clave de acceso) and a list of blobs. The blobs listed are 'pacientes.csv', 'pacientes_clean.csv', and 'pacientes_features.csv'.

(b) Evidencia uso de la nube. Contenedor Azure

7 Manifiesto uso IA

Se utilizó la IA como un asistente técnico durante el desarrollo del proyecto, específicamente para la revisión de código, detección de errores y también conformación para algunas decisiones como ventajas y desventajas de usar un modelo. Además, fue un apoyo para la sintaxis en generación de plots y también del modelo de regresión logística.